SISTEMAS DISTRIBUÍDOS

Escalabilidade em Sistemas Distribuídos

Victor Vinícius Figueiredo Silva

1. Definição de Escalabilidade

A capacidade de um sistema funcionar bem quando a carga ou o número de usuários aumenta.



2. Escalabilidade Vertical (Scaling Up)

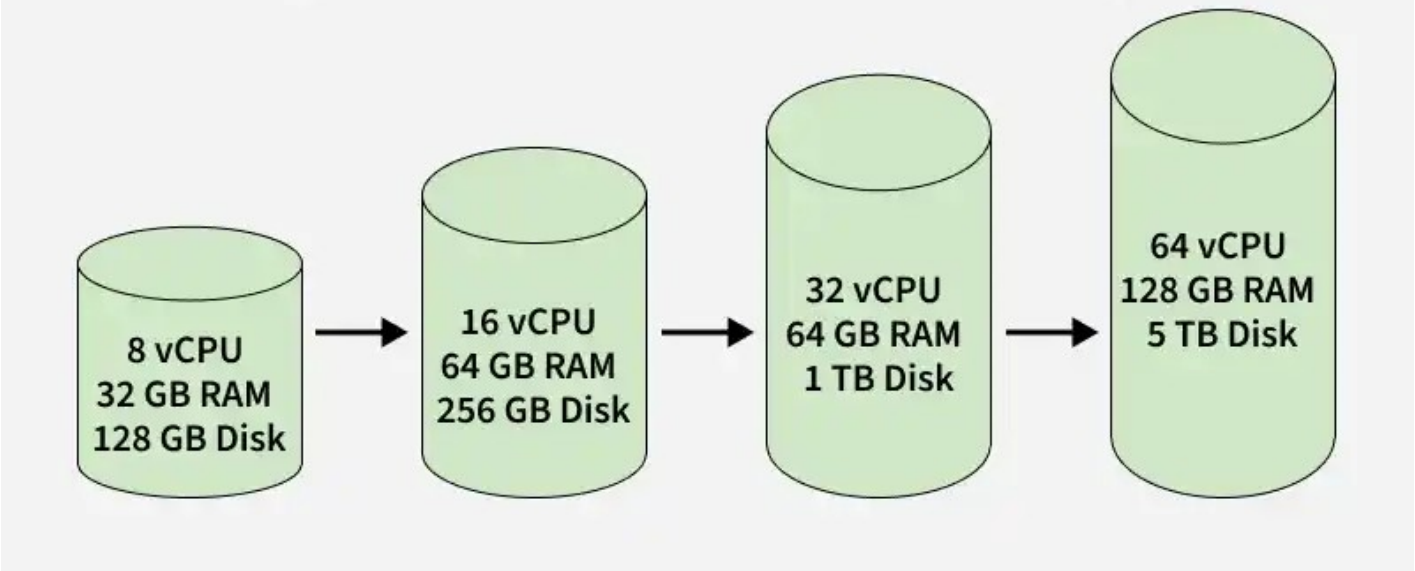
Aumentar a capacidade de um componente individual.

Vantagens

- Mais simples de implementar
- Mais eficiente em clusters menores

Desvantagens

- Limite físico de hardware
- Geralmente exige downtime
- Hardware topo de linha é caro



3. Escalabilidade Horizontal (Scaling Down)

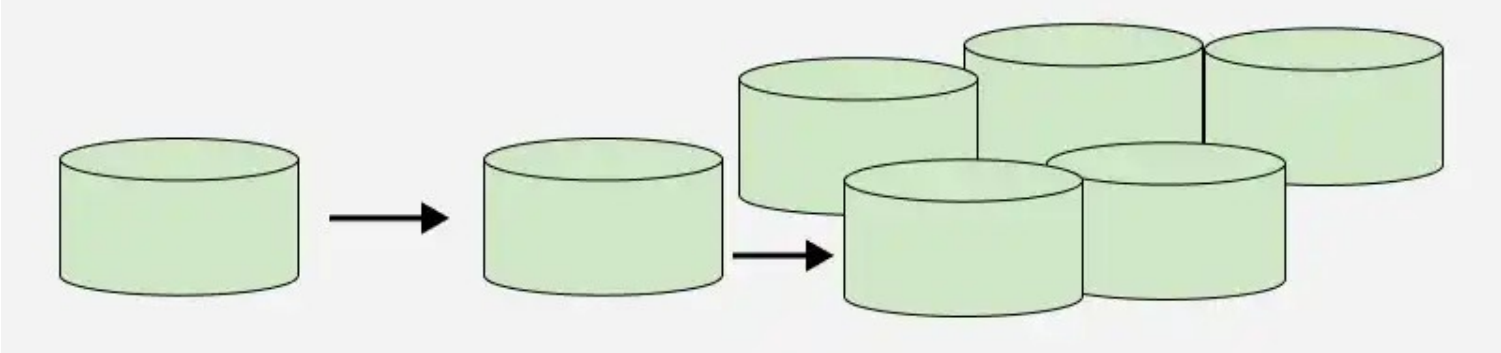
Distribuir o sistema em vários nós independentes, mas coordenados entre si.

Vantagens

- Tolerância a falhas e redundância
- Menor tempo de inatividade total

Desvantagens

- Exige balanceadores e orquestração
- Difícil manter consistência de dados
- Comunicação entre nós afeta latência



Quando aplicar cada abordagem?

Escalabilidade Vertical

- Cargas de trabalho previsíveis
- Alto poder computacional localizado (ex.: bancos relacionais de leitura intensiva)
- Equipe com recursos limitados para gerir infraestrutura distribuída

Escalabilidade Horizontal

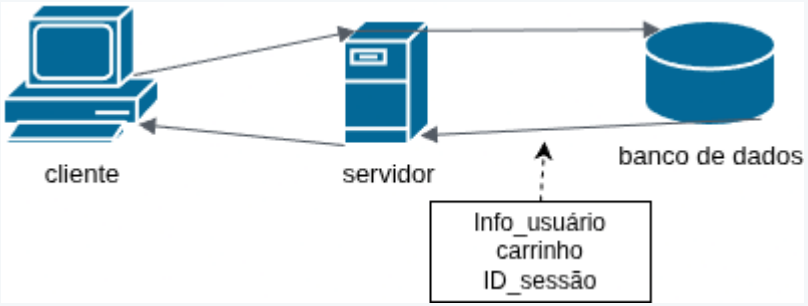
- Aplicações web de alto tráfego
- Plataformas de mídia social e e-commerce
- Microsserviços, alta disponibilidade e crescimento dinâmico

4. Componentes Stateful vs. Stateless

Stateful

O sistema lembra o contexto do cliente entre requisições.
Ex.: carrinho de compras armazenado na memória do servidor.

- Rápido para requisições repetidas do mesmo cliente
- Consome mais RAM/armazenamento no servidor
- Falha do servidor = perda do contexto do usuário
- Protocolos: FTP, TCP, sticky sessions



Stateless

Cada interação é tratada como transação independente.
O contexto vem na própria requisição ou em um backend compartilhado.

- Load balancer roteia livremente para qualquer instância
- Falha de um servidor não perde dados de sessão
- Mais consultas a bancos/caches externos
- Protocolos: HTTP, UDP, tokens JWT, Round Robin



5. Load Balancers

Processo de distribuição de tráfego de rede ou cargas de trabalho computacionais entre vários servidores, recursos ou processos em uma rede.



Otimização de recursos

Evita que um único servidor fique sobrecarregado.



Maximização do desempenho

Aumenta o tráfego geral e minimiza o tempo de resposta.



Redundância

Em falha de um servidor, desvia o tráfego para os restantes.

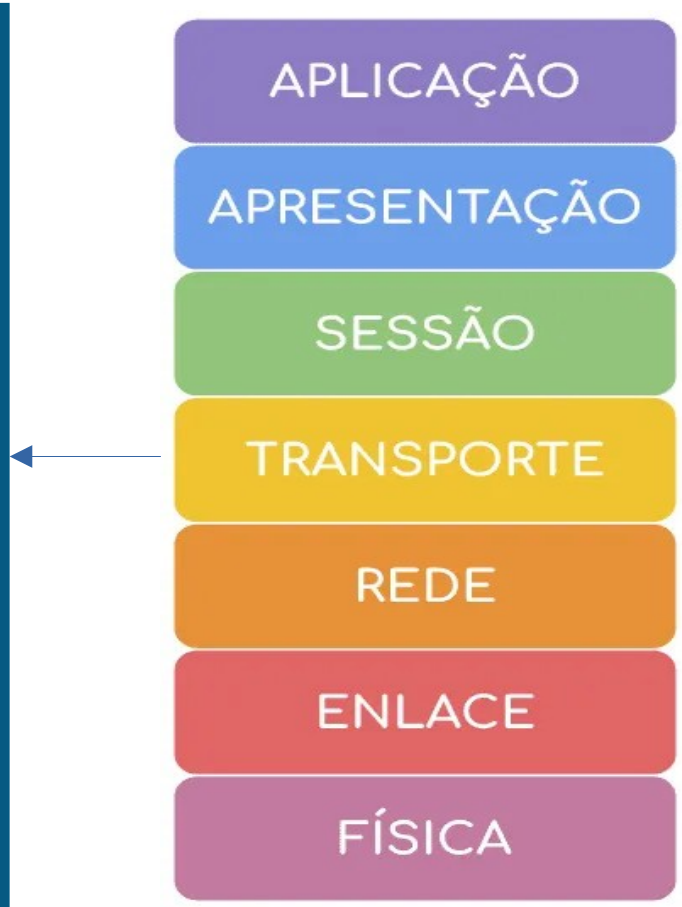
Load Balancers: L4 vs. L7

Operam em diferentes camadas do modelo OSI

L4

Camada de Transporte

- Decide o roteamento com base em IP de origem/destino e portas TCP/UDP
- Não inspeciona o conteúdo da aplicação
- Extremamente rápido, menor sobrecarga computacional
- Limitado em decisões de roteamento detalhadas



L7

Camada de Aplicação

- Inspeciona URLs, cabeçalhos HTTP, cookies e tipo de dado
- Roteamento inteligente e sensível ao contexto
- Permite SSL termination, WAF, roteamento por path
- Mais lento devido à inspeção de pacotes

Principais Algoritmos de Load Balancing

ESTÁTICOS

- **Round Robin**

  Distribui o tráfego para uma lista de servidores em rotação, via registros DNS.

- **Round Robin Ponderado**

  Atribui pesos diferentes — servidores mais capazes recebem mais tráfego.

- **Hash IP**

  Combina IPs de origem e destino em um hash para atribuir a conexão a um servidor.

DINÂMICOS

- **Menor Conexão**

  Envia tráfego para o servidor com menos conexões abertas no momento.

- **Menor Conexão Ponderada**

  Combina menor conexão com pesos por capacidade de cada servidor.

- **Tempo de Resposta Ponderado**

  Combina tempo médio de resposta com nº de conexões abertas.

- **Baseado em Recursos**

  Um agente mede CPU/memória de cada servidor antes de rotear.

6. Arquitetura: Public Load Balancer + Private Backend



Segurança

Backends sem IP público não podem ser atacados diretamente. Todo tráfego passa pelo LB, que atua como WAF (Web Application Firewall) filtrando requisições suspeitas.

Escalabilidade Dinâmica

Instâncias privadas podem ser adicionadas ou removidas conforme a demanda, de forma transparente — sem alterar o IP acessado pelos usuários.